

Universidad Técnica Particular de Loja

Dirección General de Tecnologías de la Información y Transformación Digital

Prácticum Interno — Línea de Datos: Ingeniería, Analítica y Visualización

Pipeline de datos del macroentorno ecuatoriano: limpieza, modelo relacional y dashboard analítico

Reto de 7 semanas · 4to y 6to ciclo · Python, PostgreSQL y Power BI

Contexto y propósito

El Tablero Macroentorno de la UTPL integra indicadores económicos y laborales de nueve fuentes públicas del Ecuador. Ese tablero existe, pero su actualización es manual y su pipeline de datos no está documentado ni es reproducible. Cuando cambia un archivo fuente, alguien tiene que saber exactamente qué hacer para actualizar el tablero — y ese conocimiento hoy vive en personas, no en código.

En este reto se construirá el pipeline de datos que hace ese proceso sostenible y reproducible: desde los archivos crudos que entrega el equipo de RPA hasta el dashboard con visualizaciones que responden tres preguntas analíticas concretas. La arquitectura sigue el modelo medallón estándar: capa Bronze (datos crudos), Silver (datos limpios en base de datos relacional) y Gold (indicadores calculados listos para visualizar).

Durante las primeras semanas, el estudiante descarga los archivos directamente desde las fuentes públicas para poder avanzar de forma autónoma. A partir de la semana 5, esos mismos archivos empezarán a llegar automáticamente del pipeline de RPA. La integración entre los dos equipos al final del reto es el entregable institucional del prácticum.

Primer entregable: diagrama de arquitectura

Antes de escribir una sola línea de código o configurar cualquier nodo, el estudiante debe diseñar y entregar el diagrama de arquitectura de su solución. Este entregable es obligatorio y debe ser aprobado por el tutor antes de que el estudiante avance al desarrollo.

El propósito del diagrama no es decorativo: es la herramienta que permite al tutor y al estudiante acordar qué se va a construir, cuánto abarca la solución y qué decisiones técnicas se toman desde el inicio. Un buen diagrama de arquitectura evita semanas de trabajo en la dirección equivocada.

El diagrama de arquitectura del pipeline de Datos debe mostrar el flujo completo desde los archivos crudos hasta el dashboard. Es especialmente importante diferenciar las tres capas del modelo medallón y mostrar cómo se relacionan las tablas del modelo relacional.

Elemento del diagrama	Qué debe mostrar
Capa Bronze	Cómo llegan los archivos crudos (descarga manual en semanas 1-4, carpeta de RPA en semanas 5-7). Qué formatos y qué fuentes.
Capa Silver	El modelo relacional: qué tablas hay, cuáles son sus claves primarias y cómo se relacionan entre sí. Mínimo el diagrama ER simplificado.
Transformaciones	Qué operaciones de limpieza se aplican a cada fuente: renombrado de columnas, nulos, duplicados, tipos de dato, normalización.
Capa Gold	Qué vistas o tablas derivadas se calculan y qué indicadores contienen. Nombre de cada vista y qué pregunta del dashboard responde.

Dashboard	Las tres páginas del dashboard con sus visualizaciones y a qué vista Gold se conecta cada una.
Integración con RPA	Cómo detecta el pipeline los archivos nuevos que deposita RPA y qué dispara el re-procesamiento.

Herramientas sugeridas para elaborar el diagrama: draw.io (gratuito, en línea, sin instalación), Lucidchart (plan gratuito disponible) o cualquier herramienta de diagramación que produzca un archivo exportable en PDF o imagen. No se acepta un diagrama dibujado a mano para el entregable formal, aunque sí como borrador inicial.

El diagrama se entrega al tutor al final de la semana 1, junto con una explicación verbal de cinco minutos donde el estudiante justifica sus decisiones de diseño. Si el tutor detecta que el alcance es demasiado ambicioso, demasiado limitado o que hay una decisión técnica incorrecta, el diagrama se revisa antes de que el estudiante comience la semana 2.

Las fuentes de datos y su estructura

El pipeline trabaja con nueve fuentes organizadas en tres bloques. A continuación se describen las columnas confirmadas de cada fuente para que el estudiante pueda comenzar a trabajar desde el primer día sin explorar el archivo desde cero.

Bloque 1 — Banco Central del Ecuador

Fuente	Columnas clave	Detalle
PIB real anual	Años, PIB_musd, Población, PIB_percapita, Variacion_pct	Serie desde 1965. El primer año tiene variación nula — es correcto, no eliminar. Leer con <code>read_excel()</code> , <code>engine='openpyxl'</code> .
PIB per cápita nominal	Período, PIB_percapita_nominal_usd	Fecha como datetime (primer día del año). Desde 2000. Comparable con cifras internacionales en dólares corrientes.
VAB por provincia e industria	AÑO, COD_PROVINCIA, PROVINCIA, COD_CANTON, CANTON, CIU, VAB_miles_usd	Estructura multi-nivel. Normalizar en <code>dim_geografia</code> antes de cargar.
Precio petróleo y riesgo país	Período, precio_petroleo_wti, riesgo_pais_pb	Frecuencia diaria. Fecha como datetime. Los dos indicadores pueden estar en el mismo archivo o en archivos separados según la versión descargada.
IEE — Expectativas Empresariales	Fecha, IEE_global, Comercio, Construcción, Manufactura	Serie mensual desde 2010. Fecha como string 'AAAA-MM-DD' — convertir a date con <code>pd.to_datetime()</code> .

Bloque 2 — INEC

Fuente	Columnas clave	Detalle
ENEMDU — Indicadores laborales	Encuesta, Periodo, Indicadores, Nacional, Urbana, Rural	Estructura pivotada: un indicador por fila, áreas como columnas. Aplicar melt() de pandas para normalizarla antes de cargar.
Censo 2022 — Rama de actividad	Provincia, Canton, Sexo, Grupo_edad, Personas_ocupadas, CIIU	Dato estático del censo 2022. Se carga una sola vez. Permite cruzar con VAB y Supercias por CIIU.

Bloque 3 — Supercias y MINEDUC

Fuente	Columnas clave	Detalle
Supercias — Ranking de empresas	RUC, Nombre, Situacion_legal, Ingresos, Activos, Provincia, CIIU	CSV descargable directamente. Permite cruzar con VAB y Censo por CIIU y con MINEDUC por provincia.
Supercias — Directorio de compañías	RUC, Nombre, Situacion_legal, Provincia, Canton	Usado principalmente para contar empresas activas por provincia — insumo de la pregunta P3 del dashboard.
MINEDUC — AMIE 2023-2024	Ao_lectivo, AMIE, Nombre_Institucion, Provincia, Canton, Nivel_Educacion, Sostenimiento, Total_Estudiantes	CSV con separador ; y encoding latin-1. Filtrar por Nivel_Educacion = 'Bachillerato' y el último grado para construir el indicador de bachilleres por provincia.

Arquitectura del pipeline

Modelo relacional — tablas Silver

```
-- Dimensión geográfica (compartida entre VAB, Supercias y MINEDUC)
CREATE TABLE dim_geografia (
  id_geo          SERIAL PRIMARY KEY,
  provincia       VARCHAR(60) NOT NULL,
  cod_provincia   INTEGER,
  canton          VARCHAR(80),
  cod_canton      INTEGER
```

```

);

-- Dimensión temporal
CREATE TABLE dim_tiempo (
    id_tiempo    SERIAL PRIMARY KEY,
    fecha        DATE NOT NULL,
    anio         INTEGER NOT NULL,
    mes          INTEGER,
    trimestre    INTEGER
);

-- Hechos: indicadores macroeconómicos anuales
CREATE TABLE fact_macro_anual (
    id            SERIAL PRIMARY KEY,
    id_tiempo     INTEGER REFERENCES dim_tiempo(id_tiempo),
    pib_real_musd NUMERIC(14,2),
    pib_percapita_nominal NUMERIC(10,2),
    variacion_pib_pct NUMERIC(6,3)
);

-- Hechos: indicadores diarios
CREATE TABLE fact_indicadores_diarios (
    id            SERIAL PRIMARY KEY,
    fecha         DATE NOT NULL,
    precio_petroleo_wti NUMERIC(8,2),
    riesgo_pais_pb INTEGER
);

-- Hechos: empleo ENEMDU
CREATE TABLE fact_empleo (
    id            SERIAL PRIMARY KEY,
    periodo       VARCHAR(10) NOT NULL,
    anio          INTEGER,
    indicador      VARCHAR(120) NOT NULL,
    total_nacional NUMERIC(14,2),
    total_urbana   NUMERIC(14,2),
    total_rural    NUMERIC(14,2)
);

-- TODO: tablas para VAB, IEE, Supercias y MINEDUC
-- Usar dim_geografia como FK donde aplique

```

Vistas Gold — indicadores calculados

```

-- Vista Gold: evolución del PIB con clasificación de ciclo económico
CREATE OR REPLACE VIEW gold_pib_tendencia AS

```

```

SELECT t.anio, m.pib_real_musd, m.variacion_pib_pct,
       CASE WHEN m.variacion_pib_pct > 2 THEN 'Crecimiento fuerte'
            WHEN m.variacion_pib_pct > 0 THEN 'Crecimiento moderado'
            WHEN m.variacion_pib_pct = 0 THEN 'Estancamiento'
            ELSE 'Contracción' END AS clasificacion
FROM fact_macro_anual m JOIN dim_tiempo t USING (id_tiempo)
ORDER BY t.anio;

-- TODO: gold_empleo_tendencia — tasa de desempleo trimestral histórica
-- TODO: gold_petroleo_30dias — promedio móvil de 30 días del WTI
-- TODO: gold_empresas_provincia — empresas activas e ingresos por provincia
-- TODO: gold_bachilleres_vs_empresas — cruce MINEDUC + Supercias por provincia

```

Las tres preguntas del dashboard

#	Pregunta analítica	Visualizaciones	Fuentes (vistas Gold)
P1	¿Cómo ha evolucionado la economía ecuatoriana en los últimos 20 años?	Línea de PIB real anual. Barras de variación con color por clasificación. KPI: último PIB per cápita y variación interanual.	gold_pib_tendencia. IEE mensual del último año para contexto de coyuntura.
P2	¿En qué sectores y provincias se concentran la actividad económica y el empleo?	Mapa coroplético de VAB por provincia. Barras de empleo por rama CIIU (top 10). KPI: tasa de desempleo más reciente.	gold_empleo_tendencia. VAB provincial. Censo 2022.
P3	¿Dónde están los bachilleres del Ecuador y cuántas empresas hay en cada provincia?	Barras agrupadas: bachilleres 3ro año vs. empresas activas por provincia. Tabla de provincias con mayor ratio. KPI: total bachilleres 3ro año nacional.	gold_bachilleres_vs_empresas — cruce MINEDUC + Supercias.

La pregunta P3 es la de mayor relevancia estratégica para la UTPL: identifica provincias con alta concentración de bachilleres próximos a graduarse y relativamente pocas empresas activas — potencial de demanda de educación superior no capturado. Ese análisis conecta directamente con el Tablero de Segmentación y Geoestadística del área de Marketing de la institución.

Cronograma de 7 semanas

Semana	Enfoque	Qué se construye	Entregable
1	Entorno y diagrama	Instalar el stack. Descargar manualmente las fuentes del BCE. Explorar el PIB real. Diseñar el diagrama de arquitectura completo (incluyendo ER del modelo relacional) y presentarlo al tutor.	Diagrama aprobado. Primera exploración del PIB real documentada.
2	Limpieza fuentes BCE	Implementar transform/bce.py con funciones para PIB real, PIB nominal, VAB, petróleo/riesgo e IEE. Cargar las cinco tablas Silver en la base de datos.	Cinco tablas BCE limpias en la BD. Documento de decisiones de limpieza.
3	Limpieza INEC, Supercias y MINEDUC	Implementar transform/inec.py (con melt() para ENEMDU), supercias.py y mineduc.py. El AMIE ya fue trabajado en el reto de semana 1 — reutilizar ese código como punto de partida.	Todas las fuentes cargadas. Pipeline ejecutando sin errores.
4	Modelo relacional y vistas Gold	Ejecutar create_tables.sql con FK correctas. Implementar los cuatro TODO de gold_views.sql. Verificar que las vistas producen resultados correctos antes de conectar el dashboard.	Modelo relacional completo. Cuatro vistas Gold funcionando.
5	Dashboard P1 y P2 + primera integración RPA	Conectar Power BI a la BD. Construir páginas P1 y P2. Coordinarse con el equipo de RPA: recibir los primeros archivos automáticos y verificar que el pipeline los procesa correctamente.	Dos páginas del dashboard. Primera integración con RPA documentada.
6	Dashboard P3 y refinamiento	Construir la página P3. Revisar las tres páginas con el tutor. Agregar filtros por año, provincia y sector. Escribir el párrafo de interpretación de cada visualización.	Dashboard completo con tres páginas, filtros y párrafos de análisis.
7	Documentación y presentación	Completar el informe técnico. Preparar la demostración. Presentar el dashboard completo mostrando la integración RPA en funcionamiento.	Informe técnico. Demo con datos de RPA. Integración demostrada.

Diferenciación 4to y 6to ciclo

Aspecto	4to ciclo	6to ciclo
Base de datos	SQLite — sin servidor, incluido en Python.	PostgreSQL — motor de producción con vistas materializadas y control de usuarios.
Fuentes	Bloque 1 (BCE) + MINEDUC. Mínimo siete tablas Silver.	Los tres bloques completos. Mínimo doce tablas Silver.
Vistas Gold	Implementar las cuatro vistas del script base.	Además, proponer y justificar dos vistas Gold adicionales no definidas en el script.
Dashboard	Tres páginas con visualizaciones y KPIs.	Tres páginas con visualizaciones, KPIs y un párrafo de análisis ejecutivo por página que conecta el dato con la estrategia de la UTPL.

Integración con el equipo de RPA

A partir de la semana 5 los archivos llegan automáticamente desde el pipeline de RPA a la carpeta `datos_macroentorno/`. El pipeline de Datos detecta los archivos nuevos y los procesa sin intervención manual. Este mecanismo es el que convierte los dos retos en un sistema integrado.

El acuerdo de integración entre los dos equipos — firmado en la semana 4 — define: el nombre exacto de las subcarpetas, el formato del nombre de archivo (fuente + fecha, ej: `pib_real_20260512.xlsx`) y el canal de notificación cuando hay archivos nuevos. Este acuerdo es un entregable formal de ambos equipos.

Entregables

1. Diagrama de arquitectura aprobado por el tutor al final de la semana 1, incluyendo el diagrama ER del modelo relacional.
2. Repositorio GitHub privado con todos los módulos ETL, el DDL SQL y el README.
3. Base de datos con todas las tablas Silver cargadas y las vistas Gold funcionando.
4. Script `pipeline.py` que detecta archivos nuevos de RPA y los procesa automáticamente.
5. Dashboard completo con tres páginas, filtros y KPIs.
6. Documento de acuerdo de integración con el equipo de RPA.
7. Informe técnico de dos páginas: arquitectura, decisiones de limpieza y hallazgos analíticos.
8. Demostración de diez minutos: pipeline con archivos de RPA, dashboard en vivo e interpretación de los tres hallazgos.

Criterios de evaluación

Criterio	Peso	Indicador principal
Diagrama de arquitectura con ER aprobado antes de desarrollar	10 %	Entregado en semana 1, ER coherente con el modelo construido
Fuentes limpias y tablas Silver correctamente cargadas	25 %	7 tablas mínimo (4to) o 12 (6to) con tipos correctos y nulos justificados
Modelo relacional con FK y vistas Gold funcionando	20 %	DDL sin errores, cuatro vistas Gold con resultados correctos
Pipeline detecta y procesa archivos nuevos de RPA	20 %	Demo: llega archivo de RPA, el pipeline lo procesa, el dashboard se actualiza
Dashboard con tres preguntas respondidas	15 %	Tres páginas funcionales con filtros, KPIs y visualizaciones correctas
Interpretación analítica y acuerdo de integración con RPA	10 %	Cada visual tiene párrafo de análisis, acuerdo firmado y documentado